

Prédire le succès d'un film avant sa sortie

Classification flop / moyen / hit à partir des données TMDB 5000

Projet machine learning · 7 notebooks · application Streamlit

Paul-César Bensemoun

Albert School — ML Proof of Concept

Le dataset TMDB 5000

Source publique de référence pour le ML cinéma

4 803

films au départ

2

fichiers (movies + credits)

1916—2017

période couverte

~20

variables exploitables

CE QU'ON A

Movies — budget, durée, genre, langue, date de sortie, sociétés et pays de production, revenu. **Credits** — pour chaque film, la liste complète du cast et de l'équipe technique au format JSON.

CE QU'ON N'A PAS

Aucun signal marché pré-sortie : budget marketing, critiques, buzz réseaux sociaux, calendrier concurrentiel. On modélise uniquement avec des variables disponibles avant le tournage.

À retenir — TMDB est suffisant pour une preuve de concept pré-sortie, mais ne contient pas les signaux marché — c'est une limite assumée du projet.

Nettoyage des données et définition du succès

Du dataset brut à un dataset de modélisation propre

NETTOYAGE


Parsing des colonnes JSON puis suppression des films sans budget ni revenu exploitables — 1 574 films retirés sur 4 803. Résultat : 3 229 films prêts à modéliser.

CIBLE

On calcule le ROI (revenu ÷ budget) uniquement pour étiqueter les films. Trois classes définies par des seuils explicites.

ANTI-LEAKAGE

Revenu, ROI, popularité et votes sont strictement interdits dans les features : on ne modélise qu'avec des signaux disponibles avant la sortie.



FLOP

ROI < 1×
24 % des films

MOYEN

1 ≤ ROI < 2×
20 % des films

HIT

ROI ≥ 2×
56 % des films

À retenir — Trois classes définies par des seuils ROI explicites — chaque film est étiqueté de façon objective et reproductible.

Premières observations sur les données

Quelles variables semblent contenir du signal ?

BUDGET

Le budget seul ne suffit pas : on trouve des hits à 5 M\$ et des flops à 200 M\$. Sa distribution est extrêmement asymétrique → échelle log indispensable.

GENRE


Profils ROI très contrastés : horreur et animation surperforment, drame et documentaire sont plus risqués.

TIMING

Saisonnalité visible : les sorties estivales et de fin d'année concentrent les meilleurs ROI.

CONCLUSION

Aucune variable seule n'explique le succès — il faut combiner et créer des signaux dérivés (feature engineering).



À retenir — Trois axes porteurs : budget, genre et timing. Cela oriente le feature engineering qui suit.

Modèle de référence (baseline)

Un premier modèle pour fixer un point de comparaison

SETUP

10 variables de base (budget, durée, genre, langue, mois de sortie). Split train / test 80 / 20 stratifié sur les 3 classes.


MODÈLES COMPARÉS

Régression logistique, forêt aléatoire, gradient boosting. Champion retenu = meilleur macro-F1 sur le test → **régression logistique** (macro-F1 ≈ 0.37 , accuracy $\approx 39\%$).

Pourquoi macro-F1 ?

- Classes déséquilibrées (~56 % hit) : l'accuracy récompense « tout prédire hit ».
- Macro-F1 = moyenne des F1 des 3 classes → chaque classe compte autant.
- C'est aligné avec l'objectif métier : détecter flop, moyen ET hit.

Baseline models — test accuracy vs macro-F1



À retenir — On compare les modèles sur macro-F1 — métrique honnête face au déséquilibre. Le baseline à 0.37 sert de référence pour toute la suite du projet.

Feature engineering : créer de nouvelles variables

Enrichir le modèle sans ajouter de nouvelles données

MÉTHODOLOGIE

Transformations Clés

Budget en échelle logarithmique pour corriger l'asymétrie extrême (1 K\$ → 380 M\$). Durée bucketisée (court / moyen / long). Décennie de sortie comme proxy d'époque.

Signaux Composites

Complexité du genre (focused / mixed / hybrid) et échelle de production (indie / mid / large) calculées sur les tertiles du train uniquement.

Gain : macro-F1 ≈ 0.39 (+0.02 vs baseline)

LES 25 VARIABLES DU MODÈLE

BUDGET & DURÉE (3)

budget_log	runtime	runtime_bucket
------------	---------	----------------

GENRE & LANGUE (5)

main_genre	genre_count	genre_complexity	original_language
spoken_lang_count			

PRODUCTION & TIMING (7)

prod_co_count	prod_country_count	intl_prod	multi_lang
prod_scale	decade	release_month	

CASTING & ÉQUIPE (8)

cast_size	top_billed_count	known_actor_count	ensemble_flag
crew_size	writer_count	dir_movie_count	top_dir_flag

SIGNAUX COMPOSITES (2)

talent_score	possible_franchise_flag
--------------	-------------------------

À retenir — Le feature engineering apporte +0.02 de macro-F1. Les variables credits ajoutées feront le plus gros bond.

Enrichissement avec les credits : le saut de qualité

On intègre le cast, l'équipe technique et la dimension franchise

SIGNAUX AJOUTÉS

Cast & Équipe : Taille du cast, acteurs connus, crew size, scénaristes.

Réalisateur : Nombre de films et flag "top réalisateur".

Franchise : Heuristique titre + keywords.


SCORE TALENT COMPOSITE

Combinaison pondérée des signaux acteurs / réalisateur pour résumer le « packaging créatif » en une seule variable.

GAIN RÉGIME CREDITS

Macro-F1 $\approx$ 0.44

(+0.07 vs baseline) · Accuracy $\approx$ 47 %



À retenir — Le plus gros gain du projet vient des signaux talent et packaging — le graphique reflète le modèle de production final.

Analyse des erreurs : qu'a apporté l'enrichissement credits ?

On compare les prédictions baseline vs credits sur le même test set

MÉTHODE

Comparaison film par film des prédictions du baseline et du modèle credits sur le même test set (646 films).

BILAN DES TRANSITIONS

- **Sauvés par les credits** : 130 films désormais corrects.
- **Perdus par les credits** : 79 films devenus faux.
- **Gain net** : +51 prédictions correctes.

LIMITE STRUCTURELLE

La classe « moyen » reste la plus difficile : c'est une fenêtre ROI étroite, pas un défaut du modèle.



À retenir — L'enrichissement credits apporte un gain net mesurable (+51 films mieux classés). La classe moyen reste le point dur — limite de la fenêtre ROI.

Validation et optimisation du modèle final

Quatre techniques pour solidifier le champion

VALIDATION CROISÉE (5 PLIS)

Macro-F1 = 0.441 ± 0.011 → performance très stable, le score test n'est pas dû à la chance.

CALIBRATION


Calibration isotonique : +10 pp d'accuracy mais -0.08 macro-F1. On garde la version non calibrée.

HYPERPARAMÈTRES

5 familles de modèles testées. La régression logistique tunée reste le meilleur compromis performance / interprétabilité.

APPROCHE EN CASCADE

Modèle ordinal (flop vs non-flop, puis hit vs moyen). Macro-F1 ≈ 0.34 → sous-performe l'approche directe.



À retenir — Performance stable en cross-validation, trade-offs documentés. On valide le champion et on le garde pour l'application.

Bilan du projet & application Streamlit

Ce qu'on a produit, les limites, et les suites possibles



CE QUI FONCTIONNE

- Pipeline complet et reproductible (7 notebooks documentés).
- Discipline anti-leakage rigoureuse à chaque étape.
- Champion de production : LR tunée, 25 features nettoyées.
- Modèle utile comme aide à la décision (44.5 % macro-F1).
- Application Streamlit : prédiction et comparaison de scénarios.

LIMITES ET SUITES POSSIBLES

- Pas de données marketing ni de buzz pré-sortie dans TMDB.
- Les films « moyens » restent durs à prédire (fenêtre étroite).
- Suite : intégrer critiques (Rotten Tomatoes, Metacritic).
- Suite : intégrer les données Box Office Mojo.
- Suite : validation temporelle (entraîner sur le passé, tester sur le futur).

À retenir — Pipeline ML rigoureux + application crédible pour un usage métier. La performance est limitée par les données disponibles, pas par la méthodologie.